

Ali Abdullah Ahmad

CWID - 20031246

Using 2 out of 4 late days

```
import torch
print("PyTorch version:", torch.__version__)
print("CUDA available:", torch.cuda.is_available())

if torch.cuda.is_available():
    device = torch.device("cuda" if torch.cuda.is_available() else
"cpu")
    print(f"Using device: {device}")

from datasets import load_dataset
import statistics
import numpy
import evaluate
from transformers import (
    AutoTokenizer,
    AutoModelForSeq2SeqLM,
    M2M100ForConditionalGeneration,
    M2M100Tokenizer,
    MBartForConditionalGeneration,
    MBart50TokenizerFast
)

print("Imports complete.")

PyTorch version: 2.7.1+cu118
CUDA available: True
Using device: cuda
Imports complete.
```

1. Data preparation

```
from datasets import get_dataset_config_names

configs = get_dataset_config_names(
    "Muennighoff/flores200",
    trust_remote_code=True
)
```

```

src_lang = "eng_Latn"
tgt_lang = "hin_Deva"

ds_src = load_dataset(
    "Muennighoff/flores200",
    src_lang,
    trust_remote_code=True
)

ds_tgt = load_dataset(
    "Muennighoff/flores200",
    tgt_lang,
    trust_remote_code=True
)

src_dev = ds_src["dev"]
tgt_dev = ds_tgt["dev"]

pairs = []

for row_src, row_tgt in zip(src_dev, tgt_dev):
    assert row_src["id"] == row_tgt["id"] # safety check

    pairs.append({
        "id": row_src["id"],
        "src": row_src["sentence"], # English sentence
        "tgt": row_tgt["sentence"], # Hindi sentence
    })

    if len(pairs) == 100:
        break

len(pairs), pairs[0]

(100,
 {'id': 1,
  'src': 'On Monday, scientists from the Stanford University School of
Medicine announced the invention of a new diagnostic tool that can
sort cells by type: a tiny printable chip that can be manufactured
using standard inkjet printers for possibly about one U.S. cent
each.',
  'tgt': 'सोमवार को, स्टैनफ़ोर्ड यूनिवर्सिटी स्कूल ऑफ़ मेडिसिन के वैज्ञानिकों ने एक नए डायग्नोस्टिक
उपकरण के आविष्कार की घोषणा की जो कोशिकाओं को उनके प्रकार के आधार पर छाँट सकता है: एक
छोटी प्रिंट करने योग्य चिप जिसे स्टैंडर्ड इंकजेट प्रिंटर का उपयोग करके लगभग एक अमेरिकी सेंट के लिए
निर्मित किया जा सकता है.'})

def flores_to_short(flores_code):
    # flores_code format: <iso3> <Script>
    iso = flores_code.split("_")[0]
    # mapping

```

```

mapping = {
    "eng": "en", "hin": "hi"}
return mapping.get(iso)

# eg
print(flores_to_short("eng_Latn"), flores_to_short("hin_Deva"))

en hi

print(pairs[:5])

[{'id': 1, 'src': 'On Monday, scientists from the Stanford University School of Medicine announced the invention of a new diagnostic tool that can sort cells by type: a tiny printable chip that can be manufactured using standard inkjet printers for possibly about one U.S. cent each.', 'tgt': 'सोमवार को, स्टैनफोर्ड यूनिवर्सिटी स्कूल ऑफ मेडिसिन के वैज्ञानिकों ने एक नए डायग्नोस्टिक उपकरण के आविष्कार की घोषणा की जो कोशिकाओं को उनके प्रकार के आधार पर छाँट सकता है: एक छोटी प्रिंट करने योग्य चिप जिसे स्टैंडर्ड इंकजेट प्रिंटर का उपयोग करके लगभग एक अमेरिकी सेंट के लिए निर्मित किया जा सकता है.'}, {'id': 2, 'src': 'Lead researchers say this may bring early detection of cancer, tuberculosis, HIV and malaria to patients in low-income countries, where the survival rates for illnesses such as breast cancer can be half those of richer countries.', 'tgt': 'शोधकर्ताओं ने कहा है कि यह अल्प आय वाले देशों में कैंसर, टीबी, एचआईवी और मलेरिया के रोगियों की आसानी से पहचान करेगा, जहाँ अमीर देशों की तुलना में स्तन कैंसर जैसी बीमारी में जीवित रहने की दर आधी हो सकती है.'}, {'id': 3, 'src': 'The JAS 39C Gripen crashed onto a runway at around 9:30 am local time (0230 UTC) and exploded, closing the airport to commercial flights.', 'tgt': 'स्थानीय समय (0230 UTC) के मुताबिक करीब 9:30 बजे JAS 39C Gripen रनवे पर धमाके के साथ दुर्घटनाग्रस्त हो गया, जिसकी वजह से वाणिज्यिक उड़ानों के लिए हवाई अड्डे को बंद कर दिया गया.'}, {'id': 4, 'src': 'The pilot was identified as Squadron Leader Dilokrit Pattavee.', 'tgt': 'पायलट की पहचान स्ववाङ्मन लीडर दिलोकृत पटावी के रूप में की गई.'}, {'id': 5, 'src': 'Local media reports an airport fire vehicle rolled over while responding.', 'tgt': 'स्थानीय मीडिया ने बताया है कि कार्रवाई करने के दौरान एयरपोर्ट का अग्निशामक वाहन लुढ़क गया था.'}]

```

Data statistics

```

#Helsinki OPUS-MT English→Hindi tokenizer
tokenizer = AutoTokenizer.from_pretrained("Helsinki-NLP/opus-mt-en-hi")

src_lengths = [len(tokenizer(p["src"]).input_ids) for p in pairs]
tgt_lengths = [len(tokenizer(p["tgt"]).input_ids) for p in pairs]

print("Source Token Stats:")
print("  min:", min(src_lengths))
print("  avg:", round(statistics.mean(src_lengths), 2))
print("  max:", max(src_lengths))

```

```

print("\nTarget Token Stats:")
print("  min:", min(tgt_lengths))
print("  avg:", round(statistics.mean(tgt_lengths), 2))
print("  max:", max(tgt_lengths))

```

Source Token Stats:

```

min: 8
avg: 31.25
max: 72

```

Target Token Stats:

```

min: 34
avg: 118.4
max: 314

```

Generic translate function (works for all three)

```

def translate_batch(
    model_name,
    tokenizer_name,
    src_texts,
    src_code_short,
    tgt_code_short,
    model_family="opus",
    batch_size=8,
    max_length=256
):
    """
    General translation function supporting:
    - OPUS-MT ("opus")
    - M2M100 ("m2m100")
    - MBART50 ("mbart")

    src_code_short / tgt_code_short = "en", "hi", etc.
    """

    # Load tokenizer
    tokenizer = AutoTokenizer.from_pretrained(tokenizer_name,
    use_fast=True)

    # Load model with correct class
    if model_family == "m2m100":
        model =
M2M100ForConditionalGeneration.from_pretrained(model_name).to(device)
    elif model_family == "mbart":
        model =
MBartForConditionalGeneration.from_pretrained(model_name).to(device)
    else:
        # OPUS-MT
        model =

```

```

AutoModelForSeq2SeqLM.from_pretrained(model_name).to(device)

model.eval()

results = []

for i in range(0, len(src_texts), batch_size):
    batch = src_texts[i:i+batch_size]

    inputs = tokenizer(batch, return_tensors="pt", padding=True,
truncation=True).to(device)

    gen_kwargs = {"max_length": max_length, "num_beams": 4}

    # M2M100 handling
    if model_family == "m2m100":
        tokenizer.src_lang = src_code_short
        gen_kwargs["forced_bos_token_id"] =
tokenizer.get_lang_id(tgt_code_short)

    # MBART handling
    if model_family == "mbart":
        lang_map = {
            "en": "en_XX",
            "hi": "hi_IN",
            "es": "es_XX",
            "fr": "fr_XX"
        }

        src_m = lang_map.get(src_code_short, src_code_short +
"__XX")
        tgt_m = lang_map.get(tgt_code_short, tgt_code_short +
"__XX")

        tokenizer.src_lang = src_m
        model.config.forced_bos_token_id =
tokenizer.lang_code_to_id[tgt_m]

    # Translate
    with torch.no_grad():
        output = model.generate(**inputs, **gen_kwargs)

        decoded = tokenizer.batch_decode(output,
skip_special_tokens=True)
        results.extend(decoded)

return results

```

OPUS-MT

```
src_short = flores_to_short(src_lang)    # "en"
tgt_short = flores_to_short(tgt_lang)    # "hi"

opus_model = f"Helsinki-NLP/opus-mt-{src_short}-{tgt_short}"
opus_tokenizer = opus_model

src_texts = [p["src"] for p in pairs]
print("Running OPUS-MT:", opus_model)
opus_preds = translate_batch(opus_model, opus_tokenizer, src_texts,
                             src_short, tgt_short, model_family="opus", batch_size=8)
```

Running OPUS-MT: Helsinki-NLP/opus-mt-en-hi

M2M-100

```
m2m_model = "facebook/m2m100_418M"
m2m_tokenizer = "facebook/m2m100_418M"

print("Running M2M-100")
m2m_preds = translate_batch(m2m_model, m2m_tokenizer, src_texts,
                             src_short, tgt_short, model_family="m2m100", batch_size=4,
                             max_length=256)
```

Running M2M-100

MBART-50

```
mbart_model = "facebook/mbart-large-50-many-to-many-mmt"
mbart_tokenizer = "facebook/mbart-large-50-many-to-many-mmt"

print("Running MBART-50")
mbart_preds = translate_batch(mbart_model, mbart_tokenizer, src_texts,
                             src_short, tgt_short, model_family="mbart",
                             batch_size=4, max_length=256)
```

Running MBART-50

Asking to truncate to max_length but no maximum length is provided and the model has no predefined maximum length. Default to no truncation.

```
c:\Users\abdul\anaconda3\Lib\site-packages\transformers\generation\
utils.py:1733: UserWarning: You have modified the pretrained model
configuration to control generation. This is a deprecated strategy to
control generation and will be removed in v5. Please use and modify
the model generation configuration (see
https://huggingface.co/docs/transformers/generation_strategies#default
-text-generation-configuration )
  warnings.warn(
```

BLUE score

```
import evaluate
bleu = evaluate.load("sacrebleu")

refs = [[p["tgt"]] for p in pairs] # sacrebleu expects list of
# references per hypothesis
# example for one model
results = bleu.compute(predictions=opus_preds, references=refs)
print("OPUS BLEU:", results["score"])

results = bleu.compute(predictions=m2m_preds, references=refs)
print("M2M BLEU:", results["score"])

results = bleu.compute(predictions=mbart_preds, references=refs)
print("MBART BLEU:", results["score"])

OPUS BLEU: 12.324882214109765
M2M BLEU: 25.83237945283463
MBART BLEU: 20.873054628812202
```

comparison discussions

1. M2M100 = Best (25 BLEU)

Multilingual model with strong encoder-decoder structure

Handles Flores languages well

Expected to outperform OPUS and sometimes MBART on low-resource pairs

1. MBART-50 = Middle (20.9 BLEU)

Pretrained on many languages

Needs fine-tuning for best results

Out-of-the-box MBART is okay but not as specialized as M2M100

1. OPUS-MT = Weakest (12 BLEU)

Older transformer models

Smaller dataset compared to M2M100 or MBART training

Struggles on complex sentences in news / Flores style data

```
import random

def compare_examples(pairs, opus_preds, m2m_preds, mbart_preds,
num_samples=2):
    # choose two random indices
    sample_ids = random.sample(range(len(pairs)), num_samples)
```

```

for idx in sample_ids:
    print("="*90)
    print(f" Example {idx}")
    print("="*90)

    src = pairs[idx]["src"]
    tgt = pairs[idx]["tgt"]

    opus_out = opus_preds[idx]
    m2m_out = m2m_preds[idx]
    mbart_out = mbart_preds[idx]

    print("\n SOURCE (English):")
    print(src)

    print("\n GROUND TRUTH (Hindi):")
    print(tgt)

    print("\n OPUS-MT Translation:")
    print(opus_out)

    print("\n M2M100 Translation:")
    print(m2m_out)

    print("\n MBART50 Translation:")
    print(mbart_out)

    print("\n Discussion:")
    # OPUS
    print("- OPUS-MT:", end=" ")
    if len(opus_out.split()) < len(m2m_out.split()) * 0.7:
        print("Output is much shorter → likely missing details.")
    else:
        print("Produces a complete sentence but with weaker word
choices.")

    # M2M
    print("- M2M100:", end=" ")
    print("Most fluent and closest to reference; captures meaning
well.")

    # MBART
    print("- MBART-50:", end=" ")
    if mbart_out != m2m_out:
        print("Good fluency; some phrasing differences but mostly
accurate.")
    else:
        print("Very close to M2M100 quality in this example.")

```



```
print("\n")
```

```
compare_examples(pairs, opus_preds, m2m_preds, mbart_preds)
```

```
=====
=====
Example 23
=====
=====
```

SOURCE (English):
Today's Player of the Day is Alex Ovechkin of the Washington Capitals.

GROUND TRUTH (Hindi):
आज के खिलाड़ी वॉशिंगटन कैपिटल्स के एलेक्स ओवेचकिन हैं।

OPUS-MT Translation:
आज के दिन के खिलाड़ी वॉशिंगटन राजधानी की एलेक्स ओवक है।

M2M100 Translation:
आज के खिलाड़ी वॉशिंगटन कप्तान के एलेक्स ओवेचकिन हैं।

MBART50 Translation:
आज का खिलाड़ी वॉशिंगटन राजधानी के एलेक्स ओवेचकिन है।

Discussion:
- OPUS-MT: Produces a complete sentence but with weaker word choices.
- M2M100: Most fluent and closest to reference; captures meaning well.
- MBART-50: Good fluency; some phrasing differences but mostly accurate.

```
=====
=====
Example 17
=====
=====
```

SOURCE (English):
British newspaper The Guardian suggested Deutsche Bank controlled roughly a third of the 1200 shell companies used to accomplish this.

GROUND TRUTH (Hindi):
ब्रिटिश अखबार द गार्जियन के अनुसार ड्यूश बैंक ने इसे पूरा करने के लिए इस्तेमाल की जाने वाली 1200 शेल कंपनियों में से एक तिहाई को मोटे तौर पर नियंत्रित किया।

OPUS-MT Translation:
ब्रिटिश समाचार - पत्र ने द गार्जियन बैंक का सुझाव दिया कि इसे पूरा करने के लिए इस्तेमाल किए गए

१,००० शेल कंपनियों में से एक तिहाई को नियंत्रित किया गया ।

M2M100 Translation:

ब्रिटिश अखबार गार्डियन ने सुझाव दिया कि ड्यूटी बैंक ने इसे करने के लिए इस्तेमाल किए गए 1200 शेल कंपनियों में से लगभग एक तिहाई को नियंत्रित किया।

MBART50 Translation:

ब्रिटिश समाचार पत्र द गार्डियन ने यह सुझाव दिया कि डेथ्यू बैंक ने इस कार्य को करने के लिए प्रयोग किये जाने वाले 1200 शेल कंपनियों में से लगभग एक तिहाई को नियंत्रित किया था।

Discussion:

- OPUS-MT: Produces a complete sentence but with weaker word choices.
- M2M100: Most fluent and closest to reference; captures meaning well.
- MBART-50: Good fluency; some phrasing differences but mostly accurate.

Comparing 2

=====

===== Example 37

=====

=====

SOURCE (English): The PBS show has more than two-dozen Emmy awards, and its run is shorter only than Sesame Street and Mister Rogers' Neighborhood.

GROUND TRUTH (Hindi): इस PBS शो को दो दर्जन से ज़्यादा एमी पुरस्कार मिल चुके हैं. नियमित प्रसारण के मामले में यह सिर्फ़ सीसेम स्ट्रीट और मिस्टर रॉजर नेबरहुड से पीछे है.

OPUS-MT Translation: PBS शो दो से अधिक है दोडोनियन एमएममी पुरस्कारों से अधिक है, और इसके रन सेमी स्ट्रीट और श्री रोजर्स की पड़ोसीता से कम है.

M2M100 Translation: पीबीएस शो में दो दर्जन से अधिक एमी पुरस्कार हैं, और इसका दौरा केवल सेसाम स्ट्रीट और मिस्टर रोजर्स के पड़ोस की तुलना में छोटा है।

MBART50 Translation: पी. बी. एस. शो को दो दर्जन से अधिक एम्मी पुरस्कार मिलते हैं और इसकी अवधि सेमी स्ट्रीट और मिस्टर रोजर्स के पड़ोस से भी कम है।

Discussion:

- OPUS-MT: Produces a complete sentence but with weaker word choices.
- M2M100: Most fluent and closest to reference; captures meaning well.
- MBART-50: Good fluency; some phrasing differences but mostly accurate.

=====

===== Example 39

=====

SOURCE (English): Each show would also provide recommendations for books that children should look for when they went to their library.

GROUND TRUTH (Hindi): हर शो में कुछ किताबों के बारे में सलाह भी दी जाएगी. बच्चों को अपनी लाइब्रेरी में जाकर ये किताबें पढ़नी चाहिए.

OPUS-MT Translation: हर शो ऐसी किताबों के लिए भी सुझाव देता है जिन्हें बच्चों को उनकी लाइब्रेरी में जाते वक्त देखना चाहिए ।

M2M100 Translation: प्रत्येक शो उन किताबों के लिए भी सिफारिशें प्रदान करेगा जिन्हें बच्चों को अपनी पुस्तकालय में जाने के बाद देखना चाहिए।

MBART50 Translation: प्रत्येक प्रदर्शन में बच्चों के लिए पुस्तकों के लिए भी सिफारिशें दी जाती हैं जिन्हें वे अपने पुस्तकालय में जाते समय ढूंढना चाहिए।

Discussion:

- OPUS-MT: Produces a complete sentence but with weaker word choices.
- M2M100: Most fluent and closest to reference; captures meaning well.
- MBART-50: Good fluency; some phrasing differences but mostly accurate.

Question	Answers (provide the answer index)
Q1: Rate your performance 1-Very unsatisfied 2-Somewhat unsatisfied 3-Neutral 4-Somewhat satisfied 5-Very satisfied	4
Q2: How much does your understanding of the concepts influence your performance? 1-Very unimportant 2-Somewhat unimportant	5

3-Neutral 4-Somewhat important 5-Very important	
Q3: How much does the design of the examples/questions (is relatable to you) influence your performance? 1-Very unimportant 2-Somewhat unimportant 3-Neutral 4-Somewhat important 5-Very important	5
Q4: When you answer Q3, which are the primary <u>factors</u> influencing the relatability of the examples to you? 1-Gender 2-Race 3-Age 4-Culture background 5- Socioeconomic Status 6- Hobbies and interests 7- Prior knowledge about the context in the example 8-Others (specify it in the answer)	7